

ASR Sistemi Üzrə Texniki Hesabat

Layihənin icrası zamanı ilk addım olaraq Mozilla Common Voice Azərbaycan dili datasetindən istifadə edilərək OpenAI Whisper-Small modelinin baza performansını yoxlanılmışdır. Baseline testi üçün test datası rəsmi saytdan və Hugging Face platformasından yüklənmiş, heç bir əlavə təlim keçirilmədən modelə tətbiq edilmişdir ki, bu zaman model 27.12% WER və 7.21% CER göstəriciləri vermişdir. Modelin dilimizə daha yaxşı adaptasiya olunması məqsədilə 200-dən çox təlim və 50 validasiya nümunəsi ilə fine-tuning prosesinə başlanılmışdır. Təlim gedərkən həm training, həm də validation loss göstəricilərinin stabil şəkildə aşağı düşdüyü müşahidə edilsə də, WER göstəricisi stabil qalmamış, əvvəlcə azalma, sonra artma və sonda yenidən eniş nümayiş etdirərək ümumi test üzərində 36.26% nəticə vermişdir. Əslində etdiyim reference və prediction yoxlamaları göstərir ki, 36 faizlik bu model kifayət qədər yaxşı işləyir və leksik mənanı tamamilə tutur, sadəcə "language force" tətbiq etmədiyim üçün bəzən dildə kiçik fonetik səhvlərə yol verir. Etdiyim müqayisələr nəticəsində bəzi səsləri yoxladım və müəyyən etdim ki, model əsasən keyfiyyətsiz audiolarda səhvlər buraxır, çünki istifadə etdiyimiz ümumi datasetin keyfiyyəti heç də yüksək deyil. Loss göstəricilərinin aşağı düşməsi ilk baxışda overfitting kimi görünə bilər, lakin mən bunun əsas səbəbinin overfitting deyil, datasetin həcmnin çox az olması qənaətinəyəm, çünki model test nümunələrinə kifayət qədər uğurlu cavablar verir. Bütün bu nəticələri əks etdirən qrafik və cədvəlləri şəkillər bölməsinə əlavə etmişəm. Təəssüf ki, hazırda Respublika səviyyəli Hackathon yarışmasında iştirak etdiyim üçün bu tapşırıqə ehtiyac olandan daha az vaxt ayıra bildim və bu səbəbdən audioları detallı şəkildə tam incələmək imkanım olmadı. Buna baxmayaraq, məhdud vaxt çərçivəsində learning rate, max length, num beams və warmup steps kimi vacib parametrlərin dəyərlərini dəyişərək müxtəlif yoxlamalar apardım. Onu da qeyd etməliyəm ki, WER parametrinin hesablanmasında bəzi xətlər ola bilər, çünki datasetdəki səslərin qarşılığında verilən cümlələrin bəzilərində sistemdən qaynaqlanan orfoqrafik uyğunsuzluqlar var idi. Yekun olaraq, Fine tuning prosesi istifadə etdiyim datasetlə çox uyğunlaşmadı, ancaq nəticələr yaxşıdır, ümumi pipeline elə səviyyədə qurulub.